

# ② Caracterizări în timp și frecvență

## Notatii și definiții de bază

3 p

Clasa de modele **ARMAX**

$$\underbrace{A(q^{-1})y[n]}_{\text{AR}} = \underbrace{B(q^{-1})u[n]}_{\text{X}} + \underbrace{C(q^{-1})e[n]}_{\text{MA}}$$

Auto-RegresivControl  
eXogenMedie  
Alunecătoare

•  $q^{-1}$  ➡ Operatorul de întârziere cu un pas.

$$(q^{-1}f)[n] = f[n-1] \quad \forall n \in \mathbb{Z}$$

Polinoame

$$A(q^{-1}) = 1 + a_1 q^{-1} + \dots + a_{na} q^{-na}$$

$$B(q^{-1}) = \text{○} b_1 q^{-1} + \dots + b_{nb} q^{-nb}$$

$$C(q^{-1}) = \text{○} 1 + c_1 q^{-1} + \dots + c_{nc} q^{-nc}$$

☞ intrarea nu se transmite instantaneu la ieșire☞ zgomotul se transmite instantaneu la ieșire

Filtru de zgomot

$$G \equiv C/A$$

Filtru de sistem

$$H \equiv B/A$$





Zgomotul alb

$e$  ➡ proces stocastic total necorelat,  
impredictibil

Zgomotul colorat

zgomot alb filtrat



Alb

Roz

## 2 Caracterizări în timp și frecvență

### Notatii și definiții de bază

Operatorul de **mediere statistică**

$$E\{y[n]\}$$

Media **statistică** a ieșirii procesului, pe ansamblul realizărilor, la momentul  $nT_e$ .

**Auto-covarianță & Covarianță**

$$r_u[k] \stackrel{\text{def}}{=} E\{u[n]u[n-k]\}$$

$$r_{uy}[k] \stackrel{\text{def}}{=} E\{u[n]y[n-k]\}$$

$$\forall k \in \mathbb{Z}$$

Arată **gradul de corelare** dintre procese sau realizări ale aceluiași proces.

**Ipoteza Ergodică**

Media **temporală** a oricărei realizări suficient de îndelungate.

$$E\{y[n]\} = \lim_{N \rightarrow \infty} \frac{1}{N} \sum_{n=1}^N y[n]$$

**Transformată Fourier**

**Directă**

$$X(e^{j\omega}) \stackrel{\text{def}}{=} \sum_{n \in \mathbb{Z}} x[n]e^{-j\omega n}, \quad \forall \omega \in \mathbb{R}$$

**Inversă**

$$x[n] = \frac{1}{2\pi} \int_{-\pi}^{+\pi} X(e^{j\omega})e^{+j\omega n} d\omega, \quad \forall n \in \mathbb{Z}$$

**determinist**

**Densitate Spectrală de Putere**

Arată **conținutul în frecvență** al proceselor.

$$\phi_{u,uy}(\omega) \stackrel{\text{def}}{=} \sum_{k \in \mathbb{Z}} r_{u,uy}[k]e^{-j\omega k}, \quad \forall \omega \in \mathbb{R}$$

$$r_{u,uy}[k] = \frac{1}{2\pi} \int_{-\pi}^{+\pi} \phi_{u,uy}(\omega)e^{+j\omega k} d\omega, \quad \forall k \in \mathbb{Z}$$

**nedeterminist**




## ② Caracterizări în timp și frecvență

Timp

Analiza tranzitorie

- Pentru estimarea timpului mort și/sau a funcției pondere.
- Utilitate redusă în IS.

🔥 determinist



Frecvență

Analiza în frecvență

- Pentru estimarea răspunsului în frecvență.

$$y \equiv h * u \iff Y(e^{j\omega}) = H(e^{j\omega})U(e^{j\omega})$$

$$\begin{aligned} u[n] &= u_0 \sin(\omega_0 n) \\ y[n] &= y_0 \sin(\omega_0 n + \varphi) \end{aligned}$$

$$\begin{aligned} y_0 &= u_0 |H(e^{j\omega_0})| \\ \varphi &= \arg H(e^{j\omega_0}) \end{aligned}$$

← Se poate trasa pentru diferite valori ale lui  $\omega_0$ .

← Dificil de estimat!

O strategie

- Pentru:  $\omega_0 = 2\pi m_0 / n_0$   $m_0, n_0 \in \mathbb{N}^*$   
 $N = 2\pi m_0 K / \omega_0 = Kn_0$

înmulțire cu sin și cos

🔥 Rezultat sensibil la perturbații.

$$\begin{cases} y_s[n] \stackrel{\text{def}}{=} y[n] \sin(\omega_0 n) = y_0 \sin(\omega_0 n + \varphi) \sin(\omega_0 n) = \frac{y_0}{2} \cos \varphi - \frac{y_0}{2} \cos(2\omega_0 n + \varphi) \\ y_c[n] \stackrel{\text{def}}{=} y[n] \cos(\omega_0 n) = y_0 \sin(\omega_0 n + \varphi) \cos(\omega_0 n) = \frac{y_0}{2} \sin \varphi + \frac{y_0}{2} \sin(2\omega_0 n + \varphi) \end{cases}$$

mediere temporală

$$\begin{cases} \bar{y}_s = \frac{1}{N} \sum_{n=0}^{N-1} y_s[n] = \frac{y_0}{2} \cos \varphi \\ \bar{y}_c = \frac{1}{N} \sum_{n=0}^{N-1} y_c[n] = \frac{y_0}{2} \sin \varphi \end{cases}$$

$$\varphi = \text{atan2}\left(\frac{\bar{y}_c}{\bar{y}_s}\right) = \text{atan2}\left(\frac{\sum_{n=0}^{N-1} y[n] \cos(\omega_0 n)}{\sum_{n=0}^{N-1} y[n] \sin(\omega_0 n)}\right)$$




## ② Caracterizări în timp și frecvență

Timp

Analiza bazată pe corelație

- Pentru estimarea secvențelor de (auto-)covarianță.

⚡ nedeterminist



Frecvență

Analiza spectrală

- Pentru estimarea densităților spectrale de putere.

Ce devine echivalența:

$$y \equiv h * u \iff Y(e^{j\omega}) = H(e^{j\omega})U(e^{j\omega})$$

Operatorul de mediere statistică este actorul principal.

$$r_{uy}[k] = \sum_{m \in \mathbb{Z}} h[m] r_u[k - m]$$

$$r_y[k] = \sum_{p \in \mathbb{Z}} \sum_{q \in \mathbb{Z}} h[p] h[q] r_u[k + p - q]$$

$$\phi_{uy}(\omega) = H(e^{j\omega}) \phi_u(\omega)$$

$$\phi_y(\omega) = |H(e^{j\omega})|^2 \phi_u(\omega)$$

Transferul densității spectrale prin sisteme liniare

O strategie complementară

$$\textcircled{E} \times y[n-k] \quad A(q^{-1})y[n] = B(q^{-1})u[n] + C(q^{-1})e[n]$$

⚡ Ecuatie cu diferențe.

⚡ Soluție analitică sau recursivă pentru modelele uzuale.

⚡ Ecuatie cu secvențe de covarianță.

$$A(q^{-1})r_y[k] = B(q^{-1})r_{uy}[k] + C(q^{-1})r_{ey}[k]$$


$\forall k \in \mathbb{N}$



## ② Caracterizări în timp și frecvență


### ➤ Caracterizări ale zgomotului alb

Timp




$$r_e[k] = E\{e[n]e[n \pm k]\} = \lambda^2 \delta_0[k], \quad \forall k \in \mathbb{Z}$$

Frecvență



$$\phi_e(\omega) = \lambda^2, \quad \forall \omega \in \mathbb{R}$$

### Densitate de probabilitate Gaussiană



$$p(e[n]) \stackrel{\text{def}}{=} \frac{1}{\sqrt{2\pi\sigma}} \exp\left[-\frac{e^2[n]}{2\sigma^2}\right], \quad \forall n \in \mathbb{Z}$$



## ② Caracterizări în timp și frecvență

### ☞ Probleme de simulare

#### Contextul de lucru

#### 2 modele

$$H_1(q^{-1}) = \frac{b_1 q^{-1}}{1 + a_1 q^{-1}}$$

ordin 1

$$H_2(q^{-1}) = \frac{b_1 q^{-1} + b_2 q^{-2}}{1 + a_1 q^{-1} + a_2 q^{-2}}$$

ordin 2

(45)

#### Programe disponibile

##### # ISLAB\_2A

- Apel: `islab_2a(C,A,N,tau_max,nr)` ;
- Modul de calcul al valorilor adevărate și estimate pentru secvențe de auto-covarianță obținute cu ajutorul unui proces ARMA[1,1]. Sunt trasate graficele secvențelor obținute. Este de asemenea trasată o realizare a zgomotului colorat rezultat. Argumentele funcției sunt următoarele:
  - C** polinomul MA (vector [1 c]);
  - A** polinomul AR (vector [1 a]);
  - tau\_max** pivotul maxim al secvențelor de auto-covarianță (implicit: 50);
  - nr** numărul realizărilor de generat (implicit: 1).



## ② Caracterizări în timp și frecvență

### Programe disponibile

### Probleme de simulare

#### # ISLAB\_2B

- Apel: `islab_2b(x,y,SNR)` ;
- Modul care simulează dependența de SNR a polilor și zerourilor unui model ARMA[2,2], determinat prin echivalarea sa cu un model AR afectat de 2 zgomote necorelate (ca în **Exercițiul 1.4**). Argumentele funcției sunt:
  - x**      partea reală a polilor modelului AR (implicit: 0.5);
  - y**      partea imaginară a polilor modelului AR (implicit: 0.5);
  - SNR**   raportul semnal-zgomot (implicit: 3).

### Rutine disponibile

#### # D\_SPEKTR

- Apel: `[w,fi]=d_spektrum(A,B,sigma2)` ;
  - Rutină auxiliară de evaluare a spectrului ieșirii unui filtru liniar discret stimulat cu un zgomot alb. Argumentele funcției sunt următoarele:
    - A**              numitorul funcției de transfer a filtrului (polinom);
    - B**              numărătorul funcției de transfer a filtrului (polinom);
    - Sigma2**      varianța zgomotului alb de la intrare.
- Funcția returnează:
- w**              axa pulsațiilor ( $\omega$ );
  - fi**              densitatea spectrală  $\phi_y$  a zgomotului colorat (de ieșire).





## ② Caracterizări în timp și frecvență

### 👉 Probleme de simulare

Rutine disponibile

#### # NOISE

- Apel: `noise(operation)` ;
- Modul de generare și simulare a zgomotelor colorate produse de modelele stocastice (45). Argumentul funcției (`operation`) este un șir de caractere din mulțimea următoare:

```
close_noise
close_noise_def
init_noise
move_p
move_z
moved_p
moved_z
moving_p
moving_z
noiseclear
show
system
winit_noise
```

(implicit)





## ② Caracterizări în timp și frecvență

### ☛ Probleme de simulare

Rutine disponibile

#### # SPEFAC

- Apel: `[a, l2]=spefac(r)` ;
- Rutină auxiliară de rezolvare a *Problemei factorizării spectrale*. Aceasta constă în determinarea unui polinom:

$$A(z) \stackrel{\text{def}}{=} z^n + a_1 z^{n-1} + \dots + a_n$$

și a varianței  $\lambda^2$  cu proprietatea:

$$\lambda^2 A(z) A(z^{-1}) = \frac{1}{2} \sum_{k=0}^n r[k] (z^k + z^{-k}), \quad (46)$$

pentru o secvență de covarianță  $\{r[0], r[1], \dots, r[n]\}$ . În mod normal, această problemă se poate formula pentru orice secvență de numere  $\{r[0], r[1], \dots, r[n]\}$ , cu condiția să fie *pozitiv definită*, adică verificând inegalitatea:

$$|r[k]| \leq r[0], \quad \forall k \in \overline{0, n}. \quad (47)$$

Problema factorizării spectrale (46) este rezolvată în cazul determinării unui model AR[n] atunci când este stimulat de un zgomot alb și se cunoaște densitatea spectrală de putere a ieșirii (deci și secvența de auto-covarianță a ieșirii, cu ajutorul formulei de inversiune (12)).

Argumentul funcției `spefac` este `r` – secvența de (auto-)covarianță (vector).

Funcția returnează:

`a` coeficienții polinomului AR (vector);

`l2` varianța zgomotului alb  $\lambda^2$  cu care trebuie stimulat modelul AR pentru a obține la ieșire exact secvența de auto-covarianță `r`.



## ② Caracterizări în timp și frecvență

### 👉 Probleme de simulare

#### Problema 2.1

Pentru a rezolva punctele următoare, se va utiliza funcția **NOISE**.

1. Să se testeze grafic dacă filtrul obținut în **Exercițiul 2.3** (de tipul lui  $H_1$  din definiția (45)) este corect.
2. Să se varieze polii filtrului  $H_2$  din definiția (45) și să se comenteze rezultatele obținute cu ajutorul funcției **NOISE**.
3. Unde trebuie amplasați polii filtrului  $H_2$  pentru a obține un filtru trece jos?
4. Unde trebuie amplasați polii filtrului  $H_2$  pentru a obține un vîrf de rezonanță la  $\omega=1$ ? Ce se poate spune despre conținutul în frecvență al semnalului analizînd realizările procesului?
5. Ce efect observați atunci cînd filtrul  $H_2$  are zeroul în vecinătatea cercului unitar?



## ② Caracterizări în timp și frecvență

### 👉 Probleme de simulare

#### Problema 2.2

Să se utilizeze modulul de simulare **ISLAB\_2A** pentru a simula un proces stocastic de model ARMA[1,1]. De exemplu, pentru a genera un process de tip AR[1] cu un singur pol în  $-0.9$ , se folosește sintaxa:

```
islab_2a(1, [1 0.9]) ;
```

În mod implicit, modulul de simulare alege: **N=100**, **tau\_max=50** și **nr=1**.

1. Să se analizeze maniera în care estimațiile funcțiilor de covarianță variază cu **N** (numărul de eșantioane) și **tau\_max** (pivotal maximal al secvenței de auto-covarianță) pentru diferite locații ale polilor.
2. Să se verifice faptul că estimațiile funcțiilor de covarianță tind către valorile adevărate pentru procese de tip AR[1] și MA[1], pe măsură ce **N** tinde către infinit.
3. Să se verifice corectitudinea rezultatelor obținute la **Exercițiile 2.1** și **2.2**.



## ② Caracterizări în timp și frecvență

### 👉 Probleme de simulare

#### Problema 2.3

Se consideră un proces stocastic asociat unui model AR[2] cu două surse de zgomot (ca în contextul **Exercițiului 2.4**), pe care dorim să îl echivalăm cu un proces descris de un model ARMA[2,2], avînd o singură sursă de zgomot. Pentru simulările care urmează, se va utiliza modulul **ISLAB\_2B**.

1. Să se analizeze maniera în care variază polii și zerourile modelului ARMA atunci cînd variază SNR. În acest context, SNR este definit prin raportul dintre varianța semnalului util  $x$  și varianța zgomotului aditiv  $v$  (cu notațiile din **Exercițiul 2.4**).
2. Să se studieze cazurile în care SNR tinde la infinit (semnalul domină zgomotul) și SNR tinde la zero (zgomotul domină semnalul). Să se comenteze modificările înregistrate de densitățile spectrale.