



# 7 Algoritmi rapizi CMMP-R și VI-R cu fereastră


## Contextul de lucru

- Există situații (în special în cazul proceselor rapid variabile) în care contribuția datelor anterioare momentului curent de reactualizare **trebuie atenuată cu rapiditate controlată**.
- Istoria comportamentului procesului poate distorsiona rezultatul operației de adaptare curentă **dacă** datele achiziționate **devin rapid învechite** și **tind să nu mai corespundă comportamentului actual al procesului**.

Cum poate fi controlată atenuarea istoriei datelor?

10 p

Prin intermediul **ferestrelor culisante** fie de-a lungul setului de date, fie de-a lungul erorilor de predicție.



→ Fereastră cu deschiderea determinată de dimensiunea orizontului de măsură.

**window**

De regulă, nenegativă.

- În acest modul, va fi abordată problema estimării recursive a parametrilor prin **minimizarea** unui **criteriu pătratic** în care **pătratul erorii de predicție curente este ponderat de o fereastră culisantă nenegativă**.

- Selecția datelor are loc prin înmulțirea valorilor ferestrei (**ponderilor**) cu valorile omoloage ale datelor.

În cazul modelelor de regresie liniară, datele sunt ponderate de **radicalul ferestrei**.

$$\mathcal{V}(\theta) = \sum_{n=1}^N w_N[n] \varepsilon^2[n, \theta]$$



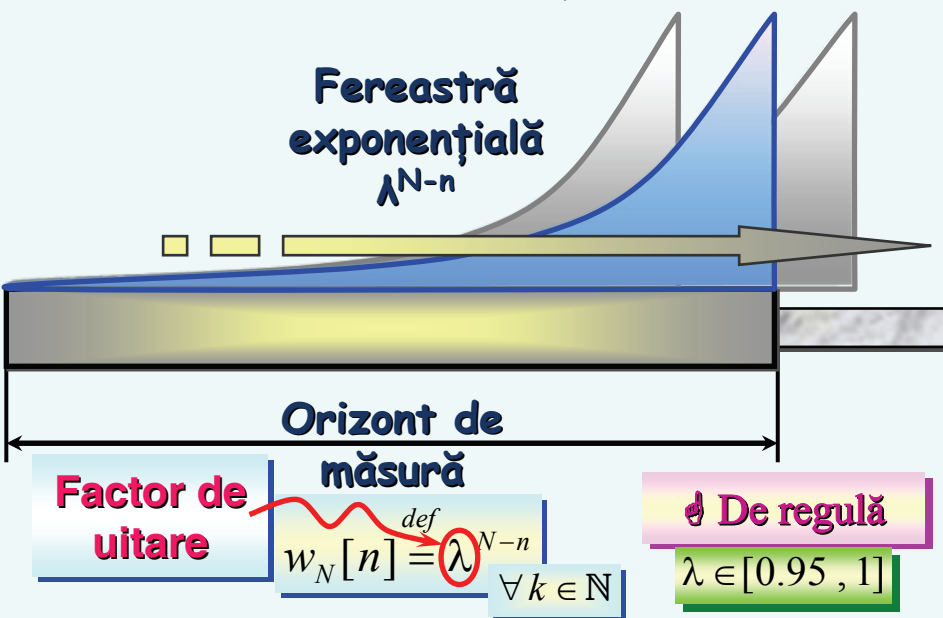
# 7 Algoritmi rapizi CMMP-R și VI-R cu fereastră

## Contextul de lucru


- Deponderarea **prea drastică** a datelor implică **deteriorarea sensibilă** a preciziei modelului de identificare, astfel că **fereastra trebuie aleasă cu atenție**.
- Aplicarea ferestrelor de ponderare asupra datelor este o **operație frecvent întâlnită** în aplicațiile de PS.
- Spre deosebire de ferestrele din aplicațiile de PS (care, de regulă, sunt **simetrice pe orizontul de măsură**), ferestrele utilizate în aplicațiile de IS pot fi **asimetrice**.

### Ferestre de culisare frecvent utilizate în aplicațiile de IS

#### Exponențială



#### Dreptunghiulară





# 7 Algoritmi rapizi CMMP-R și VI-R cu fereastră

## Contextul de lucru

### Algoritmul CMMP/VI recursiv cu fereastră exponențială

#### ➤ Date de intrare:

- ordinele modelului de identificare:  $n_a$ ,  $n_b$ ,  $n_c$ ,  $n_d$  și  $n_f$ ;
- factorul de uitare:  $\lambda \in [0, 1]$  (de regulă,  $\lambda \in [0.95, 0.995]$ );
- o colecție redusă de date intrare-ieșire măsurate (dacă este posibil):  
 $\mathcal{D}_{N_0} = \{u[n]\}_{n \in \overline{1, N_0}} \cup \{y[n]\}_{n \in \overline{1, N_0}}$  (cu  $N_0$  de ordinul zecilor, cel mult);
- un semnal instrumental extern:  $\{f[n]\}_{n \geq 1}$  (eventual).

1. Dacă nu a fost specificat nici un semnal instrumental, vectorul variabilelor instrumentale,  $\zeta$ , este identic cu vectorul regresorilor  $\phi$ . Altfel,  $\zeta$  este definit ca în cazul MVI, dar folosind în general semnalul instrumental extern  $f$  în locul intrării  $u$  (în particular, este posibil ca  $f \equiv u$ ).

2. Inițializare. Fie se setează arbitrar vectorul parametrilor  $\hat{\theta}_0$  și matricea  $P_0 = \alpha I_{n_\theta}$  (cu  $\alpha \in \mathbb{R}_+^*$ ) (în cazul în care nu se dispune de setul de date redus  $\mathcal{D}_{N_0}$ ), fie se estimează valoarea inițială a parametrilor ( $\hat{\theta}_0$ ) folosind o metodă off-line adecvată modelului particular utilizat (din clasa MCMMP-MVI) și se egalează matricea  $P_0$  cu inversa matricii de covarianță  $R_0$  folosită în calculul lui  $\hat{\theta}_0$  (în cazul în care setul de date redus  $\mathcal{D}_{N_0}$  este disponibil).

3. Pentru  $k \geq 1$ :

3.1. Se evaluează eroarea de predicție:  $\varepsilon[k] = y[k] - \phi^T[k] \hat{\theta}_{k-1}$ .

3.2. Se vectorul auxiliar:  $\xi_k = P_{k-1} \zeta[k]$ .

3.3. Se evaluează câștigul de senzitivitate:  $\gamma_k = \frac{\xi_k}{\lambda + \phi^T[k] \xi_k}$ .

3.4. Se reactualizează inversa matricii  $R_k$ , adică:  $P_k = \frac{1}{\lambda} (P_{k-1} - \gamma_k \phi^T[k] P_{k-1})$  (cu evitarea inversării explicite a matricilor).

3.5. Se reactualizează vectorul parametrilor:  $\hat{\theta}_k = \hat{\theta}_{k-1} + \gamma_k \varepsilon[k]$ .

➤ Date de ieșire: parametrii  $\hat{\theta}_k$  ai modelului de identificare la fiecare pas de reactualizare  $k \geq 0$ .



# 7 Algoritmi rapizi CMMP-R și VI-R cu fereastră

## Contextul de lucru

### Algoritmul CMMP/VI recursiv cu fereastră dreptunghiulară

#### ➤ Date de intrare:

a. ordinele modelului de identificare:  $n_a$ ,  $n_b$ ,  $n_c$ ,  $n_d$  și  $n_f$ ;

b. lungimea ferestrei dreptunghiulare:  $M$ ;

c. o colecție redusă de date intrare-ieșire măsurate:

$$\mathcal{D}_M = \{u[n]\}_{n \in \overline{1, M}} \cup \{y[n]\}_{n \in \overline{1, M}};$$

d. un semnal instrumental extern:  $\{f[n]\}_{n \geq 1}$  (eventual).

1. Dacă nu a fost specificat nici un semnal instrumental, vectorul variabilelor instrumentale,  $\zeta$ , este identic cu vectorul regresorilor  $\varphi$ . Altfel,  $\zeta$  este definit ca în cazul MVI, dar folosind în general semnalul instrumental extern  $f$  în locul intrării  $u$  (în particular, este posibil ca  $f \equiv u$ ).

2. Inițializare. Se estimează valoarea inițială a parametrilor ( $\hat{\theta}_0$ ) folosind o metodă off-line adecvată modelului particular utilizat (din clasa MCMMP-MVI, cu datele  $\mathcal{D}_M$ ) și se egalează matricea  $P_0$  cu inversa matricii de covarianță  $R_0$  folosită în calculul lui  $\hat{\theta}_0$ .

3. Pentru  $k \geq 1$ :

3.1. Se evaluează eroarea de predicție la dreapta:  $\varepsilon_d[k] = y[k] - \varphi^T[k] \hat{\theta}_{k-1}$ .

3.2. Se evaluează eroarea de predicție la stînga:

$$\varepsilon_s[k-M] = y[k-M] - \varphi^T[k-M] \hat{\theta}_{k-1}.$$

3.3. Se reactualizează matricea  $P_k$  în 2 pași:

$$\bullet \xi_k = P_{k-1} \zeta[k] \text{ și } P_{k-1} \leftarrow P_{k-1} - \frac{\xi_k \varphi^T[k] P_{k-1}}{1 + \varphi^T[k] \xi_k};$$

$$\bullet \xi_k = P_{k-1} \zeta[k-M] \text{ și } P_{k-1} \leftarrow P_{k-1} + \frac{\xi_k \varphi^T[k-M] P_{k-1}}{1 - \varphi^T[k-M] \xi_k}.$$

3.4. Se reactualizează vectorul parametrilor:

$$\hat{\theta}_k = \hat{\theta}_{k-1} + P_k (\zeta[k] \varepsilon_d[k] - \zeta[k-M] \varepsilon_s[k-M]).$$

➤ Date de ieșire: parametrii  $\hat{\theta}_k$  ai modelului de identificare la fiecare pas de reactualizare  $k \geq 0$ .



# 7 Algoritmi rapizi CMMP-R și VI-R cu fereastră

## Contextul de lucru

### Procesul generator de date

$$\text{ARX}[2,2] \quad (1 + a_1[n]q^{-1} + a_2[n]q^{-2})y[n] = (b_1[n]q^{-1} + b_2[n]q^{-2})u[n] + e[n]$$

$$\forall n \in \mathbb{N}^*$$

### Parametri variabili

$$a_1[n] \stackrel{\text{def}}{=} \frac{1}{2} \cos\left(\frac{7\pi(n-1)}{N}\right)$$

$$a_2[n] \stackrel{\text{def}}{=} 2 \exp\left(\frac{1-n}{N}\right)$$

$$b_1[n] \stackrel{\text{def}}{=} \frac{3}{4\pi} \arctg\left((-1)^n \frac{n}{N}\right)$$

$$b_2[n] \stackrel{\text{def}}{=} \frac{10 \cdot 5^{-n}}{1 + \frac{n \% 25}{N}}$$

$$\forall n \in \mathbb{N}^*$$

$e \rightarrow$  SPAB Gaussian sau bipolar de medie nulă și dispersie unitară

Date generate  $\mathcal{D} = \{u[n]\}_{n=1, \overline{N}} \cup \{y[n]\}_{n=1, \overline{N}}$

ales liber de către utilizator  $\rightarrow N \geq 200$

Pe un orizont mare de timp, modelul ARX[2,2] tinde să devină un model ARX[1,1].

Indici structurali sunt cunoscuți  $na = nb = 2$

Test de stop  $\rightarrow$  Epuizarea datelor de pe orizontul de măsură.

### Obiectiv

- Compararea performanțelor metodelor recursive de identificare cu și fără fereastră, în cazul modelelor de tip ARX.







# 7 Algoritmi rapizi CMMP-R și VI-R cu fereastră

## Probleme de simulare

### Problema 8.1 (Generarea datelor cu modelul ARX[2,2] avînd parametrii variabili)

Folosind modelul funcției `gdata_vp` (din cadrul aplicației nr. 7), proiectați și implementați o rutină generatoare de date corespunzătoare modelului ARX[2,2] prezentat anterior. Denumiți noua rutină `gdata_arx` și testați funcționarea ei generînd cîteva seturi de date, cu lungimi cuprinse între 200 și 2000. Afișați variațiile parametrilor modelului și datele de intrare-ieșire. Ce se poate spune despre stabilitatea modelului? Oferiți o explicație cît se poate de bine argumentată.

Rutină ce trebuie proiectată

`gdata_arx`

### Problema 8.2 (Algoritmi recursivi cu fereastră exponențială)

Se va testa funcționarea algoritmilor CMMP/VI recursivi cu fereastră exponențială pentru modelul ARX[2,2].

- Implementați algoritmul CMMP/VI recursiv cu fereastră exponențială prin intermediul funcției `rarx_e` (după modelul funcției `riv`). Unul dintre argumentele de intrare va trebui să fie factorul de uitare  $\lambda$ .
- Plecînd de la mini-simulatorul `ISLAB_7D`, implementați mini-simulatorul `ISLAB_8A`, care adaugă rutina `rarx_e`. Efectuați o analiză comparativă exhaustivă cu ajutorul acestuia, pentru diferite seturi de date generate și diferiți factori de uitare. (Se vor alege și seturi de date din finalul orizontului de măsură, pentru durate mari, de peste 1000 de eșantioane).

Program & rutină ce trebuie proiectate

`ISLAB_8A`

`rarx_e`



# 7 Algoritmi rapizi CMMP-R și VI-R cu fereastră

## Probleme de simulare

### Problema 8.3 (Algoritmi recursivi cu fereastră dreptunghiulară)

Se va testa funcționarea algoritmilor CMMP/VI recursivi cu fereastră dreptunghiulară pentru modelul ARX[2,2].

- Implementați algoritmul CMMP/VI recursiv cu fereastră dreptunghiulară prin intermediul funcției **rarx\_r** (după modelul funcției **rarx\_e**). Unul dintre argumentele de intrare va trebui să fie deschiderea ferestrei  $M$ .
- Plecînd de la mini-simulatorul **ISLAB\_8A**, implementați mini-simulatorul **ISLAB\_8B**, care adaugă rutina **rarx\_r**. Efectuați o analiză comparativă exhaustivă cu ajutorul acestuia, pentru diferite seturi de date generate și diferite deschideri ale ferestrei. (Se vor alege și seturi de date din finalul orizontului de măsură, pentru durate mari, de peste 1000 de eșantioane). Observați variațiile parametrilor pentru a alege o valoare satisfăcătoare a deschiderii ferestrei, măcar pentru buna urmărire a unuia dintre acești parametri.

Program & rutină ce  
trebuie proiectate

**ISLAB\_8B**

**rarx\_r**